

Echos der Antike

*Menschliche und LLM-basierte Übersetzungen
klassisch-griechischer Texte im Vergleich*

VORLAGE

Ströbel & Maier (2025)

PUBLIKATION

CHR 2025, Anthology of Computers and
the Humanities, Bd. 3

DAUER

ca. 15-20 Minuten

Übersetzen als literaturwissenschaftliches *Kernproblem*

Translation gives no idea of the original -- denn es ist unmöglich, die Bedeutung von Texten zu rekonstruieren, die in heute tot gewordenen Sprachen und Kulturen verfasst wurden.

Włodzimierz Lengauer (2013) -- bewusst provokante These

ÜBERSETZUNG ALS INTERPRETATION

- **Benjamin (1923):** Übersetzung als 'Nachhall' des Originals -- perfekte Äquivalenz strukturell unmöglich
- **Derrida (1987):** Jede Übersetzung ist Transformation und kreative Handlung
- **Jakobson (1959):** Übersetzen als interpretative Umkodierung

KONKRETE HERAUSFORDERUNGEN

- **Poetische Sprache:** Hexameter, Formeln, Epitheta (ρόδοδάκτυλος Ἥως)
- **Kulturelle Konzepte:** ἀρετή = Trefflichkeit + Tugend + Tapferkeit zugleich
- **Historische Referenzen:** kontextuelles Wissen unabdingbar
- **Ambiguität:** verschiedene Interpretationen desselben Textes

Homers Odyssee: über 70 englische Übersetzungen -- keine ist identisch. Übersetzung ist stets 'Nacherzählen'.

Digitale Geisteswissenschaften und Übersetzungsforschung

Seit den 1990er Jahren verändert das Parallelkorpus die Übersetzungswissenschaft: subjektive Urteile weichen empirisch messbaren Phänomenen.

Corpus-based Translation Studies

Baker (1993): Explizierung, Vereinfachung, Normalisierung als quantifizierbare Übersetzungstendenzen

Digitale Konkordanz & Alignment

Palladino et al. (2022/23): Wortebenen-Alignierung zwischen englischen und persischen Übersetzungen altgriechischer Texte

LLMs in der Übersetzung

GPT-4o, Gemini, Claude: Erstmals maschinelle Übersetzungen auf potenziell expertenniveller Verlässlichkeit (Wannaz & Miyagawa 2024)

Die entscheidende Frage, die der Forschungsstand bisher nicht beantwortet hat: Wie verhalten sich LLM-Übersetzungen systematisch gegenüber dem Spektrum menschlicher Übersetzungsentscheidungen? Replizieren, rekombinieren oder re-interpretieren sie das Original?

Welche stammt von einem Menschen?

A

»Die ferne Antike ... lässt sich aufgrund des Zeitablaufs nicht eindeutig feststellen, doch die Beweise ... deuten auf die Schlussfolgerung hin, dass es weder im Krieg noch in anderen Angelegenheiten etwas von großem Ausmaß gab.«

B

»Denn obwohl die Ereignisse der fernen Antike ... aufgrund des Zeitablaufs nicht eindeutig festgestellt werden können, deuten alle Beweise einer so weit zurückreichenden Untersuchung darauf hin, dass es ... etwas von großem Ausmaß gab.«

C

»Denn es war unmöglich, die früheren Ereignisse klar zu erfassen ... aber aus den Belegen, die ich so weit wie möglich zurückverfolgt habe, schließe ich, dass sie weder in Bezug auf Kriege noch in anderer Hinsicht von Bedeutung waren.«

A ist der Mensch -- kaum zu unterscheiden von B?



Cawley (1914)

✓ Mensch

»Die ferne Antike ... lässt sich aufgrund des Zeitablaufs nicht eindeutig feststellen, doch die Beweise ... deuten auf die Schlussfolgerung hin, dass es weder im Krieg noch in anderen Angelegenheiten etwas von großem Ausmaß gab.«



Claude 3.5 Sonnet

LLM -- folgt A fast wörtlich

»Denn obwohl die Ereignisse der fernen Antike ... aufgrund des Zeitablaufs nicht eindeutig festgestellt werden können, deuten alle Beweise ... darauf hin, dass es ... etwas von großem Ausmaß gab.«



GPT-4o

LLM -- kombiniert Hammond & Mynott

»Denn es war unmöglich, die früheren Ereignisse klar zu erfassen ... aber aus den Belegen ... schließe ich, dass sie weder in Bezug auf Kriege noch in anderer Hinsicht von Bedeutung waren.«



DER ARTIKEL

Ströbel & Maier (2025): Überblick und Fragestellung

Universität Zürich · CHR 2025

Welches *Echo* hinterlässt der antike Geist in modernen Übersetzungen?

Was wir das 'Echo' des antiken Denkens nennen, approximieren wir durch die Menge semantischer und stilistischer Beschränkungen, die über Übersetzer und Systeme hinweg bestehen bleiben -- operative Spuren der Rezeption.

Ströbel & Maier (2025), S. 35

DREI TEILFRAGEN

- **Konvergenz:** Wo stimmen Mensch und LLM stilistisch und lexikalisch überein?
- **Trainings-Abdruck:** Auf welche menschlichen Vorbilder sind LLMs kalibriert?
- **Interpretationsvielfalt:** Bewahren LLMs die Breite

BEITRAG DER STUDIE

- **Parallelkorpus:** reproduzierbar, alle Übersetzungen aligniert
- **Metriken-Toolkit:** Stil, Lexik, Syntax, Semantik quantifiziert
- **Erste Belege:** LLM-Konvergenz auf dominant zirkulierende Übersetzungen

Perspektive: Übersetzungsunterschiede sind kein Rauschen, sondern historische Rezeptionsspuren -- messbare Signale darüber, wie die Antike in der Moderne verstanden wird.

Das Parallelkorpus -- Texte und Übersetzer

HOMER · ODYSSEE (EPIK)

Übersetzer	Jahr
Robert Fitzgerald	1961
Richmond Lattimore	1965
Robert Fagles	1996
Anthony S. Kline	2004
Emily Wilson	2017
Peter Green	2018

THUKYDIDES · HISTORIAE
(HISTORIOGRAPHIE)

Übersetzer	Jahr
Richard Cawley	1914
Rex Warner	1954
Martin Hammond	2009
Jeremy Mynott	2013

Gattungskontrast methodisch zentral: Epik (Vers, Formeln, Epitheta [„formelhafte Epitheta"]) vs. Historiographie (Prosa, Argumentationsdichte). Zeitspanne: über 100 Jahre Übersetzungsgeschichte (1914-2018).

Griechische Quellkritik: Homer, Odyssee (Murray-Edition, 1919); Thukydides, Historiae (Oxford, 1942) · Annotation: odyCy → CoNLL

LLMs als Übersetzer -- Drei Modelle, ein Prompt

GPT-4o

OpenAI · gpt-4o

dominantes Modell 2024, breite

Trainingsbasis

Gemini 1.5 Pro

Google · gemini-1.5-pro

multimodal, lange Kontextfenster

Claude 3.5 Sonnet

Anthropic · claude-3-5-sonnet-20240620

starke Instruktionsfolge, Alignment

SCHRITT 01

Übersetzung

einheitlicher Prompt für alle drei LLMs - je 3 zusätzliche Übersetzungen

SCHRITT 02

→ Alignierung

Claude 3.5 Sonnet aligniert Quell- und Zielsätze (1:n und XML-Format)

SCHRITT 03

→ Annotation

spaCy en_core_web_md: Tokenisierung, POS-Tagging, Lemmatisierung

SCHRITT 04

→ Evaluation

TTR · POS · Kollokationen · BLEU/ROUGE/METEOR/chrF++ · LaBSE

Methodische Pointe: Derselbe Prompt + API-Batch-Verarbeitung garantiert Vergleichbarkeit. LLMs erhalten keine menschlichen Übersetzungen als Referenz -- Ähnlichkeiten entstehen allein aus den Trainingsdaten.

Das Metriken-Toolkit -- Was wird gemessen?

LEXIKALISCH / STILISTISCH

- **TTR (Type-Token-Ratio):** Anteil verschiedener Wortformen -- Maß für Wortschatzvielfalt
- **POS-Verteilung (UPOS):** Substantive, Verben, Adjektive usw. -- Gattungs- und Stilprofil
- **Kollokationsanalyse:** Bi-/Trigramme via PMI, χ^2 , Log-Likelihood -- charakteristische Phrasen

AUTOMATISCHE ÜBERSETZUNGSQUALITÄT

Metrik	Fokus
BLEU	n-Gramm-Präzision (Oberfläche)
ROUGE	n-Gramm-Recall (Inhalt)
METEOR	+ Stemming, Synonymie, Paraphrase
chrF++	Zeichen-n-Gramme, morphologiesensitiv
Kosinus-Ähnlichkeit	LaBSE-Embeddings (semantisch)

Kritischer Hinweis: BLEU/ROUGE messen Oberflächenähnlichkeit -- hohe Werte bedeuten Nähe zur Referenzübersetzung, nicht notwendigerweise bessere Qualität. METEOR und LaBSE erfassen semantische Nähe besser, sind aber ebenfalls trainingsbasiert.



ERGEBNISSE


Was zeigen die Daten?

Lexik · Wortarten · Kollokationen · Treue-Werte

Lexikalische Diversität — TTR | Was steht im Paper, was bleibt offen?

HOMER · ODYSSEE


Skala 0–0.35



$p > 0.05$ — kein signifikanter Abstand Lattimore/LLMs (§5.1.1)

THUKYDIDES · HISTORIAE

Skala 0–0.20



t-Tests Historiae: keinerlei signifikante Unterschiede (§5.1.1)

? Offene Frage — LLM-Mittelwerte nicht tabellarisch ausgewiesen

Das Paper bestätigt: LLMs liegen „stets am unteren Ende“ (§5.1.1) — aber exakte Durchschnittswerte fehlen als Tabelle. Aus Abb. 1 grob schätzbar: Homer-LLMs ≈ 0.19 – 0.22 · Thuk.-LLMs ≈ 0.09 – 0.12 . t-Tests $p > 0.05$ (Lattimore vs. LLMs): statistisch nicht signifikant. → Wie groß ist der Abstand genau — und wäre er bei größerem Korpus signifikant?

■ Exakter Wert §5.1.1 ■ Abb. 1 (Schätzung) □ ? Nicht dokumentiert — offene Frage

Originaltext-TTR: §5.1.1. Menschl.-Bereich: Abb. 1 (per Buch, kein Mittelwert ausgewiesen). Skalierungen separat wie in Abb. 1.

Wortart-Profile -- Syntaktische Gattungssignaturen

BEFUND

Homer: 'substantivlastig'

Höherer Substantivanteil -- charakteristisch für die formelhaft-nominale Sprache des Epos: Epitheta, Kenningar, nominale Prädikate.

Thukydides: 'verbreich'

Höherer Verbanteil -- charakteristisch für die syntaktisch dichte, periodische Prosa der Historiographie: Handlungsketten, Subordination.

BEDEUTUNG FÜR DIE ANALYSE

- **Gattungswissen quantifiziert:** was Poetik und Stilistik qualitativ beschreiben, ist in POS-Daten direkt sichtbar
- **Gattungssignaturen stabil:** Mensch und LLM reproduzieren die strukturellen Eigenschaften des Ausgangstexts
- **Prosa leichter zu replizieren:** LLMs zeigen bei Thukydides besonders engen POS-Anschluss
- **Stilometrie-Grundlage:** POS-Verteilung als Übersetzerfingerabdruck auf syntaktischer Ebene

Kollokationen -- LLMs spiegeln ihre Trainingsvorbilder

SCHLÜSSELBEFUND: THUK. I.1.3

Derselbe Satz, vier Übersetzer, drei LLMs -- alle verschieden. Doch:

Claude 3.5 Sonnet $\approx$ Cawley (1914)

Satzstruktur und Konnektoren-Wahl folgen Cawley auffällig eng -- qualitative Ähnlichkeit in Satzbau und Bindewörtern

GPT-4o + Gemini $\approx$ Hammond + Mynott

'remote antiquity' vs. 'preceding period': Kombination aus Elementen beider neuerer Übersetzungen. GPT-4o $\leftrightarrow$ Cawley: χ^2 -Test $p = 0.007$ (Trigramme-Ranking)

INTERPRETATION: STILISTISCHER
ABDRUCK

- **Kein Beweis für direktes Memorieren**, aber starkes Indiz für stilistischen Abdruck aus häufig zitierten, gemeinfreien Übersetzungen
- **Cawley (1914) ist gemeinfrei** und massiv im Web präsent - GPT-4o zeigt dies statistisch ($p=0.007$), Claude qualitativ
- **Menschliche Übersetzer** zeigen ebenfalls Interkorrelation, aber auch individuelle Lösungen
- **Konsequenz:** LLMs konvergieren auf dominante Muster; interpretativer Raum wird nicht erweitert

Werkzeuge: NLTK · Spearman- ρ und Kendall- τ auf ersten 1.000 Kollokationen · PMI, Chi-Quadrat, Log-Likelihood

Treue-Werte -- Automatische Evaluation

THUKYDIDES · HISTORIAE

LLM	Referenz	Sem. Ähnl	BLEU	chrF++
Claude Sonnet	Mynott	0.777	0.176	42.2
Claude Sonnet	Cawley	0.668	0.144	35.7
GPT-4o	Mynott	0.756	0.129	37.6
Gemini	Mynott	0.764	0.154	40.3

HOMER · ODYSSEE

LLM	Referenz	Sem. Ähnl	BLEU	chrF++
Claude Sonnet	Lattimore	0.744	0.140	36.0
GPT-4o	Lattimore	0.729	0.123	34.0
Gemini	Lattimore	0.736	0.131	34.9

SCHLÜSSELBEFUND

Alle drei Modelle kommen bei Homer unabhängig voneinander Lattimore am nächsten.

CLAUDE
0.744

GEMINI
0.736

GPT-4O
0.729

Drei Modelle. Derselbe Übersetzer.

-- BLEU misst Nähe, nicht Qualität -- hohe Werte zeigen Reproduktion des Referenzübersetzers

-- LaBSE-Kontamination: Ähnlichkeit LLM→Original teils

Thukydides: alle drei LLMs kommen Hammond, Mynott und Warner am nächsten (Claude / Mynott: 0.777)



E I N O R D N U N G

Was bedeutet das für die Literaturwissenschaft?

Grenzen · Potenziale · Offene Fragen

Gesamtbild -- *Konvergenz* statt Kreativität

LLMs können etablierte Übersetzungsentscheidungen annähern -- aber sie verstärken konventionelle Wiedergaben, statt den interpretativen Raum zu erweitern.

Was LLMs können

- ✓ Strukturell konsistente Übersetzungen
- ✓ Gattungssignaturen reproduzieren
- ✓ Annäherung an Mittelfeldübersetzer-Niveau
- ✓ Schnelle Alignierung (via Claude)

Was LLMs nicht können

- ✗ Interpretative Vielfalt bewahren
- ✗ Kreative Einzellösungen entwickeln
- ✗ Kulturelle Tiefeninterpretation (ἀρετή)
- ✗ Metrum übersetzen (Hexameter)

Methodischer Mehrwert

- ★ Quantitative Loci for Close Reading
- ★ Trainingsdaten-Transparenz sichtbar
- ★ Reproduzierbare Übersetzungsvergleiche
- ★ Historische Rezeptionsforschung

Zentrale Einsicht: Die quantitativen Ergebnisse ersetzen keine Nah-Lektüre -- sie priorisieren sie, indem sie Stellen maximaler interpretativer Divergenz markieren.

Grenzen der Studie und *Ausblick*

METHODISCHE EINSCHRÄNKUNGEN

- **Kleines Korpus:** nur zwei Texte -- Ergebnisse nicht ohne Weiteres generalisierbar
- **Nur Englisch:** kein Vergleich über Sprachen hinweg
- **Kontamination:** LaBSE und LLMs könnten Ausgangstexte in den Trainingsdaten haben
- **Automatische Metriken** erfassen literarische Qualität und poetische Wirkung nicht

GEPLANTE ERWEITERUNGEN

- **Korpuserweiterung:** weitere Gattungen (Lyrik, Tragödie), weitere Sprachen (Latein, Koptisch)
- **Memorierung vs. Generalisierung:** systematischer Test
- **Interpretativer Distanzindex:** semantische Ähnlichkeit mit Konzeptinventaren (Ritual, Polity)
- **Ziel:** rekonstruieren, wie die Antike in verschiedenen Epochen verstanden wurde

Rather than seeking a single correct translation, we reconstruct how antiquity is being understood. -- Stroebel & Maier (2025), S. 42

Das Echo — Was bleibt

Übersetzungsunterschiede sind keine Fehler, sondern historische Rezeptionsdokumente -- messbare Spuren davon, wie der antike Geist in moderner Sprache nachhallt.

BEFUND 1 · GATTUNG

Gattungsunterschiede (Epik vs. Historiographie) sind dominant -- sie prägen Lexik und Syntax stärker als individuelle Übersetzer- oder LLM-Entscheidungen.

BEFUND 2 · LLM-KONVERGENZ

LLMs konvergieren auf dominante menschliche Übersetzungen (Lattimore für Homer, Hammond/Mynott für Thukydides) -- stilistischer Trainingsdaten-Abdruck.

BEFUND 3 · INTERPRETATIONSVIELFALT

Menschliche Übersetzer bewahren größere interpretative Vielfalt -- besonders in der Epik. LLMs replizieren, statt zu interpretieren.

BEFUND 4 · METHODIK

Quantitative Metriken sind kein Qualitätsurteil -- sie priorisieren Close-Reading-Loci; der Interpretationsdruck bleibt beim Menschen.

Drei kritische Fragen

Frage 01 · Trainingsdaten und Kanonisierung

Verstärken LLMs bestehende Kanonisierungen -- und marginalisieren minoritäre Lesarten des antiken Textes?

Wilson (2017): Stilprofil weicht stark von Lattimore ab. Würde eine LLM-Dominanz solche Stimmen unsichtbar machen?

Frage 02 · Metriken und literarische Qualität

BLEU/ROUGE messen n-Gramm-Überschneidungen -- was ist mit poetischer Qualität, rhythmischem Nachhall, kultureller Resonanz?

Cawley (1914) ist gemeinfrei und LLMs nahe -- aber sagt ein hoher BLEU-Wert etwas über literarische Qualität?

Frage 03 · Das Echo und das Original

Misst die Studie das antike Original -- oder die Trainingsdatenbasis der LLMs, die eine bestimmte Rezeptionstradition widerspiegelt?

Lengauer: Gemessen wird kumulierte Rezeptionsgeschichte, nicht Altgriechisch. Problem -- oder Erkenntnisgewinn?